

2026 腾讯犀牛鸟开源人才培养计划 - 开源课题实战项目申请书

基于 [开源项目实战-项目申请书模板 #37](#) 填写

申请课题：YOLO-Master MoT 架构消融对比、路由可解释性与混合架构探索

Issue 链接：<https://github.com/Tencent/YOLO-Master/issues/54>

文档状态：2026 年 7 月 31 日 — 与简历同步 + 补充完整实验数据

一、时间规划

"腾讯开源课题实战"为期 1 个月（即 8 月 1 日 ~ 9 月 10 日），组委会将分别在 8 月初、8 月底联系项目导师获取入围学生的实战情况与评价。

当前进度（截至 2026-07-23）

阶段	计划时间	实际时间	状态
准备 + 训练预演	7 月	7 月（已完成）	✅ 提前完成
实战期	8.1 ~ 9.10	-	🕒 待开始

说明：由于 RTX 5060 Laptop (8GB) 单模型训练约 13 小时（MoT 慢 8.6 倍），三变体 + 混合架构训练总耗时已在 **7 月全部完成**（共约 50 小时训练），8 月实战期将主要用于**成果完善、PR 提交、社区互动**。

期望获得的成长/收益

- 架构设计能力**：深入理解 MoT（Mixture of Transformer）动态路由机制，掌握多专家模型的设计范式
- 科研方法论**：具备消融实验设计、路由可解释性分析、场景化洞察产出的完整科研能力
- 开源协作经验**：熟悉 GitHub PR 流程、代码审查规范、技术文档撰写，与社区开发者建立联系
- 低资源训练经验**：在 8GB 显存条件下探索高效训练策略，积累边缘 AI 部署的工程经验
- 论文潜力**：将路由可解释性分析与低资源训练方法整理为可发表的科研工作

期望熟悉的技术/模块

技术方向	具体内容
模型架构	YOLO-Master 的 MoT/MoA/MoE 混合架构设计与路由机制
训练优化	混合精度训练、Gradient Checkpointing、低显存训练策略
路由分析	Hook 机制、专家激活热力图、路由分布可视化
模型评估	mAP、FLOPs、Latency benchmark、消融实验设计
边界测试	Pytest 覆盖率、NaN 检测、形状一致性验证
开源协作	GitHub PR、Issue 管理、技术文档撰写

周计划（修正版：实际 + 后续）

周次	时间	主要任务	交付物	状态
预演	7.1~7.23	设备调试 + 训练预演 + 任务 1-5 全部完成	checkpoint + 测试代码 + 路由分析	✅ 已完成
第 1 周	8.1~8.7	完善 04-10 文档，撰写 GitHub Discussion 文章初稿	Discussion 草稿	⌚ 待开始
第 2 周	8.8~8.14	提交边界测试 PR + 混合架构 YAML PR	2 个 PR 合并	⌚ 待开始
第 3 周	8.15~8.21	路由可解释性深入分析 + 场景化洞察 ≥ 3 条	热力图 + 分析报告	⌚ 待开始
第 4 周	8.22~8.31	应对社区反馈 + 补充实验 + 完善 Discussion	最终 Discussion 文章	⌚ 待开始
收尾	9.1~9.10	整体交付物归档 + 实战总结	完整项目交付	⌚ 待开始

二、开源经历

本次自己参与的 issue 链接和心得体会

Issue 链接: <https://github.com/Tencent/YOLO-Master/issues/54>

心得体会:

MoT（Mixture of Transformer）架构通过动态路由机制，在单次前向传播中自适应选择 LocalConvTransformer、WindowTransformer、DeformableTransformer 三种专家，使模型能针对

不同输入特征（密集小目标、遮挡不规则目标等）激活最合适的 Transformer 变体。这种“条件计算”范式在保持推理效率的同时，显著提升了模型的表达能力。

我已从三个层面深入该课题：

1. **实验层面**（✅ 已完成）：在 VisDrone（航拍密集小目标）数据集上完成三变体消融对比，量化 MoT 相比 MoE 基线和 MoA 对比组的精度与效率增益
2. **分析层面**（✅ 已完成）：通过 Hook 机制提取路由决策，绘制专家激活热力图，揭示不同场景下各 Transformer 专家的激活模式与偏好
3. **工程层面**（✅ 已完成）：在 8GB 显存（RTX 5060）条件下完成全部训练，验证低资源训练策略（混合精度 + 小 batch）

工作经历（校内组织 + 实验室）

西二在线工作室 · 核心成员 / Unity 方向组长（2025 — 至今）

- 通过 Unity、前端考核入组，自主学习完成 Golang 后端、AI 方向考核，达成**前后端全栈开发能力**
- 现任 Unity 方向组长、前端方向组员，曾任活动宣传组临时组长，为重构后的宣传组搭建基础架构
- 负责纳新宣传、组织管理及核心事务
- 借助平台完成**大四川美 Unity 毕设项目交付**，市场价约 1 万元，成功落地

福州大学校团委综合办公室 · 骨干（2025 — 至今）

- 完成日常值班任务，积极参与团委建设与日常活动组织
- 凭借计算机技术能力**轻量化秘书处德育整理等工作流程**
- 参与中央团校调研、跨年演唱会、福大附属中学六一活动等重要活动记录拍摄

福州大学青年通讯社 · 干事（2025 — 至今）

- 参与中央团校调研福大记录拍摄工作
- 跨年晚会摄制、各学院代表新年祝福语活动等大型活动拍摄
- 入学以来**志愿时长累计 239.28 小时**

曾经参与其他开源项目

- **西二在线工作室**（校内技术组织）：担任 Unity 方向组长、活动宣传组临时组长，负责项目开发与团队管理，Golang 及 AI 方向考核自主通关
- 服务器部署到备案全流程经验，具备全栈开发与运维能力

具备的上手能力或开发经验

1. **模型训练经验**：参与郭昆实验室联邦图与医疗大模型课题，具备 PyTorch 模型训练与调优的实战经验
2. **竞赛代码实践**：2025 年全国大学生数学建模竞赛福建赛区本科二等奖（代码手），具备快速实现算法原型与实验 pipeline 的能力

3. **全 栈 开 发 能 力** : React/Vue/Astro/TypeScript/Tailwind/Node.js/Go/Python/Unity3D/Docker/Linux 完整技术栈，具备从模型设计到工程部署的端到端能力
4. **SRTP 科研项目**：作为负责人立项第 32 期国家级自选型 SRTP 项目，具备独立规划与推进科研课题的能力
5. **校内组织管理**：校团委综合办公室骨干、青通社干事，具备团队组织与跨部门协作能力
6. **项目交付经验**：通过西二在线工作室完成商业级 Unity 毕设项目交付，熟悉从需求对接、技术方案到交付验收的全流程

技术栈掌握程度

技术方向	熟练度	经验说明
前端开发	熟练	React、Vue.js、Astro、TypeScript、Tailwind CSS、HTML5/CSS3、Vite/Webpack
后端开发	熟练	Node.js、Go (Golang)、Python、PostgreSQL、Redis、REST API、Nginx
AI / 数据科学	熟练	机器学习、数据挖掘、数学建模、PyTorch、联邦学习、图神经网络
游戏开发	熟练	Unity3D (C#) — 商业级毕设项目交付
运维 / DevOps	有项目经验	Docker、Linux、服务器部署、备案全流程
目标检测	有项目经验	YOLO 系列模型训练与部署（本次课题）
CUDA/GPU	了解	RTX 5060 设备日常使用与优化
Git/GitHub	日常使用	团队协作、版本管理、PR 流程

三、其他资料

学生个人简历

- **姓名**：张伟林
- **学校**：福州大学 计算机与大数据学院 24 级软件工程
- **综测排名**：48/143（前 33.56%）
- **专业成绩排名**：59/143（前 41.26%）
- **补考科目**：0
- **志愿时长**：239.28 小时

获奖情况

学科竞赛（按简历顺序排列）：

年份	赛事	奖项	角色
2026	全国大学生服务外包创新创业大赛（A22 企业命题赛道）	东部赛区三等奖	队长
2026	中国大学生计算机设计大赛	福建省二等奖	队长
2025	全国大学生数学建模竞赛	福建赛区本科二等奖	代码手
2026	计算机学院第八期院第二课题"金课"	冠军小组	组长

赛事级别说明： - 全国大学生服务外包创新创业大赛：教育部**五星级 A 类**赛事，31 家行业领军企业命题 - 中国大学生计算机设计大赛：教育部**A 类**赛事，游戏制作赛道 - 全国大学生数学建模竞赛：**全球最大规模**数理建模专项竞赛，72 小时团队作战 - 计算机学院"金课"课题：院内重点课题（组长身份）

其他参赛： - 美国大学生数学建模竞赛（MCM/ICM） - 全国大学生电工数学建模竞赛 - 全国大学生统计建模竞赛 - CCF BDCI 全国大数据与人工智能创新大赛 - CCSCW2025 协同智能大数据专项赛事

荣誉奖励：

- ★ **2025 年国家励志奖学金优秀代表**
- ★ **2026 年计算机学院五四优秀学生干部代表**

科研：

- 第 32 期国家级自选型 SRTP 项目负责人**（进行中）
- 郭昆实验室科研实习生：联邦图学习、医疗大模型两大课题
- 大一完成本科生实习知识清单全部学习内容
- 协同研究生参与 CCF BDCI 全国大数据与 AI 创新大赛
- 参与 CCSCW2025 协同智能大数据专项赛事

参与意愿

我是一名福州大学软件工程专业的大二学生，目标在目标检测与边缘 AI 推理方向深造读研，同时积极寻求大厂实习机会。

参与 YOLO-Master MoT 架构探索课题，既能发挥我在模型训练和 C++ 部署方面的实战经验，又能深入理解 CVPR 2026 级别的前沿模型架构设计。我拥有 RTX 5060（8GB 显存）设备，已在低资源条件下完成全部训练与验证（**7 月已提前完成**），这一方向本身具有学术创新价值。

我承诺在实战期内（8 月 1 日 ~ 9 月 10 日）全身心投入课题，按时完成所有交付物（PR + Discussion 技术文章），并为 YOLO-Master 社区贡献高质量的开源代码与文档。

四、项目申请书附件

硬件环境（已实测确认）

项目	配置
GPU	NVIDIA GeForce RTX 5060 Laptop (8GB GDDR7)
CPU	AMD Ryzen / Intel (已支持 CUDA 13.0)
内存	16GB+
操作系统	Windows 11
CUDA	13.0
PyTorch	2.9.1+cu130

软件环境

项目	版本
Python	3.10.9 (conda 环境 <code>yolo-master</code> , 从 <code>mamba_sm120</code> 克隆)
ultralytics (YOLO-Master)	最新版 (editable install)
peft	0.18.1
wandb	0.28.0
tensorboard	2.21.0

实验环境已验证

```
# 已完成环境搭建与验证
PyTorch: 2.9.1+cu130
CUDA: 13.0
Device: NVIDIA GeForce RTX 5060 Laptop GPU
YOLO-Master MoT/MoA modules OK
[check-build] Build check passed
```

实际训练时间记录（已实测，2026-08-01 校准）

变体	batch	imgsz	显存峰值	单 epoch	100 epochs 总耗时	训练状态
v08 (MoE 基线)	8	640	5.76GB	~6.5 min	13.28 h (47,813.7s)	✅ 已完成
v08_moa2 (MoA v2)	8	640	~6.5GB	~6.5 min	10.89 h (39,211.2s)	✅ 已完成
v084 (v08 第4次调优)	8	640	~6.5GB	~8 min	13.28 h (47,813.7s)	✅ 已完成
v08_mot6 (MoT 第6次调优)	8	640	~6.5GB	~11.7 min	19.52 h (70,272.2s)	✅ 已完成
v08_moe_mot_lite（混合架构探索）	8	640	~6.5GB	~13 min	~22 h	⚠️ 提前停止（17 epochs，废弃）
v08_moe_mot_shared（方案 D ★）	8	640	~6.5GB	~22.4 min	37.33 h (134,390s)	✅ 唯一完成训练的混合架构

总计： 6 个有效变体 / 约 95 小时训练（已全部完成）。耗时差异源于 Deformable + Window Attention 引入额外计算开销。

实验数据目录（已实测，2026-08-01）

```
Codes/YOLO-Master/experiments_zviolin/runs/
├─ v084/                # v08 第4次调优 (3.14M params, 13.28h)
├─ v08_moa2/            # MoA v2 (3.20M params, 10.89h)
├─ v08_mot6/            # MoT 基准 (3.71M params, 19.52h, 最高 mAP50-95=16.93%)
├─ v08_moe_mot_shared/  # ★ 方案 D: 跨尺度 Expert 共享 (3.00M params, 37.33h)
│   └─ args.yaml
│   └─ results.csv      # 100 epochs 完整训练日志
│   └─ weights/{best.pt,last.pt} # 6.5 MB 模型权重
├─ build_summary.csv    # 4 方案构建摘要
├─ latency_cpu_640.csv  # CPU 延迟数据
├─ latency_cuda_0_640.csv # GPU 延迟数据 (修复后实测)
├─ summary.csv          # 训练指标汇总
└─ test_results.txt     # pytest 边界测试输出

# 路由分析数据 (2026-07-31 新增)
├─ mot_routing/         # v08_mot6 路由分析
│   └─ routing_summary.csv # 18 行 (6 层 × 3 专家)
│   └─ recommendations.json # 3 条场景化推荐
└─ mot_routing_shared/  # 方案 D 路由分析
    └─ routing_summary.csv # 18 行
    └─ recommendations.json # 3 条场景化推荐
```

实验核心结果（已实测，2026-07-31）

1. 任务 1（三变体训练）核心数据

变体	mAP50-95	mAP50	Params (M)	训练状态
v08 (MoE 基线)	16.84%	29.79%	3.14	✅ 已训练
v08_moa (MoA 对比)	16.80%	29.55%	3.20	✅ 已训练
v08_mot (MoT 基准)	16.93%	29.77%	3.71	✅ 已训练（最高 mAP）

2. 任务 2（性能对比）核心数据（实测方案 D 创新点，2026-08-01 标准 benchmark 重测）

指标	v08_mot (MoT 基线)	v08_moe_mot_shared (方案 D ★)	变化
参数量 (M)	3.71	3.00	-19.1% ✅
CPU 延迟 (ms)	172.660	170.853	-1.05%（持平，未达 10% 阈值，CPU kernel launch 瓶颈）
GPU 延迟 (ms)	55.441	49.416	-10.84% ✅ 达标
mAP50-95	16.93%	16.80%	-0.13%（损失极小，可接受）
mAP50	29.77%	29.52%	-0.25%（损失极小）
moe_loss	-	9.95e-05	✅ 完全稳定

协同增益判定：按 Issue #54 "mAP > 1% 或 延迟 > 10%"二选一标准，GPU 延迟 -10.84% 已达标，架构创新成立。 GPU 提升机制：shared expert pool 减少显存访问带宽，RTX 5060 Laptop GPU 上体现为 6.025ms 延迟下降。

3. 任务 3（路由可解释性）核心数据（实测，2026-07-31）

v08_mot6 (MoT 基准) 路由分析：

专家	平均激活率	设计假设	验证状态
LocalConvTransformer	69.4%	基础特征提取	✅ 验证
WindowTransformer	12.6%	密集/规则排列场景	✅ 验证
DeformableTransformer	18.0%	遮挡/不规则目标	✅ 验证

专家差异化路由分布（实测）： - 浅层（model.14）：LocalConv 完全主导（100% / 93.5%） - 中层（model.20）：三专家均激活（67.8% / 19.8% / 12.5%） - 深层（model.23）：Window + Deformable 主导（44% / 56%），LocalConv 不激活

方案 D 路由分析对比：

指标	v08_mot6	v08_moe_mot_shared (方案 D)	变化
LocalConv 平均激活率	69.4%	46.2%	-23.2% (SharedExpertMoE 减少浅层冗余)
Window 平均激活率	12.6%	35.0%	+22.4% (跨尺度特征共享提升 Window 相关性)
Deformable 平均激活率	18.0%	18.8%	+0.8% (保持稳定)

4. 任务 4 (混合架构) 方案 D 核心创新

架构创新点： P3/P4 层共享 expert pool (P3 浅层 + P4 中层用同一组 expert) ， 通过 SharedExpertMoE 模块实现跨尺度特征交互。

实现位置： - 模块： `ultralytics/nn/modules/moe/shared_expert_moe.py` (类级别注册表 `_SHARED_POOLS`) - 配置： `ultralytics/cfg/models/master/v0_8/det/yolo-master-moe-mot-shared-n.yaml`

修复工程教训 (245ms → 49.4ms , 2026-08-01 标准 benchmark 复测) ： - **问题：** SharedExpertMoE 类级别 `_SHARED_POOLS` 注册表未正确传播 device, 导致 CPU/GPU 隐式 transfer - **修复：** 在 `_apply()` 方法中同步 expert device + 添加 `reset_shared_pools()` 类方法清空注册表 - **效果：** GPU 延迟从早期错误数据 245.310ms → 真实数据 **49.416ms (-80%)** , 重新校准了所有 benchmark 数据

5. 任务 5 (边界测试) 核心结果 (2026-08-01 实测)

- 测试数量: **30 个** (`tests/test_mot.py` 14 个 + `tests/test_moa.py` 16 个)
- 通过率: **30/30 = 100%** 
- 已修复 bug: `test_moa.py` 中 `NameError: name 'nn' is not defined` (已添加 `import torch.nn as nn`)

五、Issue #54 完整任务分析

5.1 六大任务总览

#	任务	类型	难度	创新空间	状态
1	三变体训练	🔒 固定执行	☆☆	低	✅ 完成
2	性能对比测量	🔒 固定执行	☆	低	✅ 完成
3	路由可解释性分析	🧠 核心创新	☆☆☆☆	高	✅ 完成
4	混合架构探索	🧠 核心创新	☆☆☆☆	高	✅ 完成 (方案 D)
5	边界测试与修复	🔒 固定执行	☆☆	低	✅ 完成 (30/30)
6	交付物	🔒 固定执行	☆☆	中	🕒 撰写中

5.2 固定路线 (已完成)

任务 1：三变体训练 ✅

子任务	模型	配置文件	训练结果
1a	YOLO-Master-EsMoE-N	yolo-master-n.yaml	mAP50=0.301, mAP50-95=0.170
1b	YOLO-Master-v0.10-MoT-N	yolo-master-mot-n.yaml	mAP50-95= 0.1693 (最高)
1c	YOLO-Master-v0.10-MoA-N	yolo-master-moa-n.yaml	mAP50-95=0.168

任务 2：性能对比 (已实测, 2026-08-01 标准 benchmark: warmup=500, reps=2000) ✅

指标	v08	v08_moa	v08_mot
Params (M)	3.14	3.23	3.71
GFLOPs	7.1	7.5	11.5
CPU Latency (ms)	59.78	78.54	172.660
GPU Latency (ms)	22.01	40.05	55.441
mAP50-95	0.16838	0.16798	0.16928

说明： v08/v08_moa 数据来自 2026-07-31 测量 (reps=1000) , v08_mot/v08_moe_mot_shared 为 2026-08-01 标准 benchmark 重测 (reps=2000) 。所有数据均已落盘到 experiments_zviolin/runs/latency_*.csv 。

任务 5：边界测试 (30 个全部通过) ✅

测试项	内容	结果
5a	window_size > feature_map 时的降级处理	✓
5b	shift 操作在奇数尺寸输入的边界	✓
5c	exploration_eps 在 eval 模式下禁用	✓
5d	MoA 辅助损失处理空模块	✓ (修复 import bug)

任务 6: 交付物 🕒 撰写中

交付物	状态
GitHub Discussion 技术总结文章	🕒 草稿撰写中 (8.1-8.7)
实验脚本仓库链接	✓ 已准备 (待上传)
边界测试 PR	🕒 待提交 (8.8-8.14)
混合架构 YAML PR (方案 D)	🕒 待提交 (8.8-8.14)
场景化洞察 ≥ 3 条	✓ 已完成 (见任务 3 文档)

5.3 创新空间 (已完成)

任务 3: 路由可解释性分析 ✓


- ✓ Hook 机制提取路由决策
- ✓ 3 个 Transformer 专家的激活热力图
- ✓ 密集 vs 稀疏、小目标 vs 大目标对比
- ✓ DeformableTransformer 在遮挡场景激活率分析

任务 4: 混合架构探索 ✓ 方案 D 创新

方案	说明	状态
A: MoE(backbone) + MoT(neck)	加 1 个 C2fMoT (P3)	🕒 仅 Benchmark, 未训练
B: MoT + MoA 交叉	全 MoE/MoT 覆盖 (5+5)	🕒 论文未来工作
C: 多类型专家路由	MoE + MoA + MoT 协同	🕒 论文未来工作
D: 跨尺度专家池共享	P3/P4 共享 expert pool	✓ 创新点: 参数-19.1%, GPU 延迟-10.84% (达标 10% 阈值), CPU 延迟-1.05% (持平)

方案 D 核心创新: 通过 `SharedExpertMoE` 模块实现跨尺度特征交互, 同时显著减少参数量和 GPU 延迟。

5.4 任务依赖关系与执行顺序（已完成）



5.5 实际进度 vs 计划进度

任务	计划周次	实际完成	提前/延后
任务 1	第 1 周 (8.1-8.7)	7.20-7.22	提前 10 天
任务 2	第 2 周 (8.8-8.14)	7.22	提前 17 天
任务 3	第 3 周 (8.15-8.21)	7.22	提前 24 天
任务 4	第 4 周 (8.22-8.31)	7.23	提前 30 天
任务 5	第 1 周 (8.1-8.7)	7.22-7.23	提前 10 天
任务 6	第 4 周 (8.22-8.31)	撰写中	按计划进行

总结：技术性任务（1-5）已全部提前完成，文档与社区交付（任务 6）将按原计划在 8 月实战期内完成。

六、后续计划（8.1-9.10）

8.1-8.7（第 1 周）

- [] 完善 05-10 任务文档（确保内容与实际数据一致）
- [] 撰写 GitHub Discussion 文章初稿
- [] 整理实验脚本仓库

8.8-8.14（第 2 周）

- [] 提交边界测试 PR（30 个测试）
- [] 提交混合架构 YAML PR（方案 D）
- [] 应对社区 code review

8.15-8.21 (第 3 周)

- [] 路由可解释性深入分析 (补充热力图)
- [] 场景化洞察最终化 (≥ 3 条)
- [] 准备导师评价材料

8.22-8.31 (第 4 周)

- [] 完善 Discussion 文章 (应对反馈)
- [] 补充实验 (如果 mentor 要求)
- [] 中期检查

9.1-9.10 (收尾)

- [] 整体交付物归档
- [] 实战总结报告
- [] 终期提交

七、预期成果价值

学术价值

1. **首次系统分析 MoT 路由机制**, 场景化洞察可作为论文素材
2. **方案 D 跨尺度专家池共享** 是新的架构创新点, 可申请专利或论文
3. **低资源训练方法** (8GB 完整训练三变体) 有方法论贡献

工程价值

1. **可复现实验脚本**, 降低社区研究者复现门槛
2. **30 个边界测试**提升 YOLO-Master 鲁棒性
3. **方案 D YAML 配置**为社区提供轻量化替代方案

社区贡献

1. **PR 合并**到主分支
2. **Discussion 文章**成为社区参考
3. **场景化推荐**帮助用户选择合适变体

撰写人：张伟林 (Zviolin) 个人博客：<https://zviolin.online/> 个人简历：<https://zviolin.online/resume/> 撰写日期：2026 年 7 月 31 日 实战期：2026 年 8 月 1 日 ~ 9 月 10 日